Rapport d'instabilité (Fang & Wang)

Pierre Chambet

Mars 2026

Résumé

On veut choisir k (nombre de clusters) et les paramètres de distance (α, ω) sans labels. Ce rapport se concentre sur une méthode de la littérature : **nselectboot** (Fang & Wang, 2012) qui minimise une **instabilité** mesurée par bootstrap. On teste une grille 21×21 en (α, ω) sur quatre jeux de données ; les labels ne servent qu'à évaluer l'ARI une fois k choisi. Une étude sur données simulées complète le rapport : données artificielles où le vrai k est connu.

Table des matières

1 Objectif de l'expérience 1 **2**

2 Les trois paramètres et les données **2**

3 nselectboot (Fang & Wang, 2012) **2**
- 3.1 Idée . . . 2
- 3.2 PAM . . . 2
- 3.3 Protocole (résumé) . . . 2
- 3.4 Résumé sur la grille . . . 2

4 Résultats : triplets retenus pour l'évaluation (nselectboot) **3**

5 Matrices de confusion (nselectboot) **3**

6 Heatmaps d'instabilité (nselectboot) **3**
- 6.1 Canadian . . . 4
- 6.2 AEMET . . . 4
- 6.3 Growth . . . 5
- 6.4 Tecator . . . 5

7 Etudes sur données simulées **5**

8 Paramètres des expériences **8**

9 Conclusion **8**

1 Objectif de l'expérience 1

On veut choisir trois quantités **sans utiliser les labels pour le choix** :
— k : nombre de clusters.
— α : pondération entre distance sur les courbes (niveau) et sur les dérivées (forme).
— ω : pondération entre partie fonctionnelle et partie vectorielle (Z).

On estime un k_{opt} qui minimise l'instabilité bootstrap. On obtient une carte $(\alpha, \omega) \mapsto k_{\text{opt}}$ et des heatmaps d'instabilité par k. Les heatmaps montrent l'instabilité par (α, ω) et k : **bleu = faible instabilité (bon)**, **rouge = forte (mauvais)**.

2 Les trois paramètres et les données

— k : nombre de clusters testé dans $\{2, \ldots, 6\}$.
— α : mélange D_0 (courbes) / D_1 (dérivées).
— ω : mélange distance fonctionnelle / distance sur Z.

Quatre jeux de données (labels uniquement pour **évaluer** après coup) : Canadian, AEMET, Growth, Tecator. Les k_{vrai} utilisés dans les tableaux viennent des scripts `src/00_preprocess*.R` : Canadian (`CanadianWeather$region`), Growth (garçons/filles), AEMET et Tecator via des règles définies dans le projet (géographie / seuils sur la matière grasse) — ce ne sont pas des vérités « absolues », mais des références pour comparer les partitions.

3 nselectboot (Fang & Wang, 2012)

3.1 Idée

On **minimise l'instabilité** : à chaque répétition bootstrap, on mesure à quel point deux partitions (obtenues sur deux échantillons bootstrap) se contredisent. Le k qui minimise cette instabilité moyenne est retenu pour le couple (α, ω) fixé.

3.2 PAM

PAM (k-medoids) travaille sur une matrice de distances ; les centres sont des **médoïdes** (individus réels), ce qui limite l'influence des outliers par rapport à des moyennes (k-means).

3.3 Protocole (résumé)

Pour chaque (α, ω) de la grille (21×21, pas 0.05), avec $B = 150$:

1. Construire $D_w(\alpha, \omega)$ (même pipeline que le reste du projet : lissage, FPCA, distances).
2. Pour chaque $k \in \{2, \ldots, 6\}$, `fpc::nselectboot` tire deux échantillons bootstrap d'indices, clusterise avec PAM sur les sous-matrices, complète les partitions sur tous les individus (classification croisée), puis agrège une mesure d'instabilité (voir code du package).
3. $k_{\text{opt}} = \arg\min_k \widehat{\text{instabilité}}(k)$.

Les fichiers `nselectboot_*.csv` et les figures `nselectboot_heatmap_*.png` synthétisent les résultats.

3.4 Résumé sur la grille

En regardant la médiane des k_{opt} sur les 441 couples : Canadian $\to$ 4, AEMET $\to$ 4, Growth $\to$ 2, Tecator $\to$ 3, cohérent avec les k_{vrai} retenus pour l'évaluation (sauf conventions sur AEMET/Tecator).

4 Résultats : triplets retenus pour l'évaluation (nselectboot)

Pour les matrices de confusion, on prend le premier couple (α, ω) de la grille tel que $k_{\text{opt}} = k_{\text{vrai}}$ (sinon le plus proche), comme dans `generate_confusion_nselectboot.R`.

Dataset	k_{vrai}	k	(α, ω)	ARI
Canadian	4	4	$(0.25, 0.15)$	0.62
AEMET	4	4	$(0.35, 0.20)$	0.39
Growth	2	2	$(0.10, 0.05)$	0.42
Tecator	3	3	$(0.75, 0.10)$	0.58

TABLE 1 – Partition évaluée avec les labels (ARI).

5 Matrices de confusion (nselectboot)

Lignes = vraies classes. Colonnes = clusters prédits.

Canadian ($k = 4$, ARI 0.62)

	C1	C2	C3	C4
Arctic	0	0	3	0
Atlantic	15	0	0	0
Continental	1	6	5	0
Pacific	0	4	0	1

AEMET ($k = 4$, ARI 0.39)

	C1	C2	C3	C4
Atlantique	9	4	0	0
Continental	2	19	0	0
Mediterranee	0	3	15	0
Sud	0	3	10	8

Growth ($k = 2$, ARI 0.42)

	C1	C2
Fille	6	48
Garcon	29	10

Tecator ($k = 3$, ARI 0.58)

	C1	C2	C3
Maigre	19	0	93
Moyen	39	23	0
Gras	2	39	0

6 Heatmaps d'instabilité (nselectboot)

Pour chaque k, l'instabilité en fonction de (α, ω). Bleu = bas = bon. $\times$ = meilleur (α, ω) pour ce k (voir script d'analyse).

6.1 Canadian

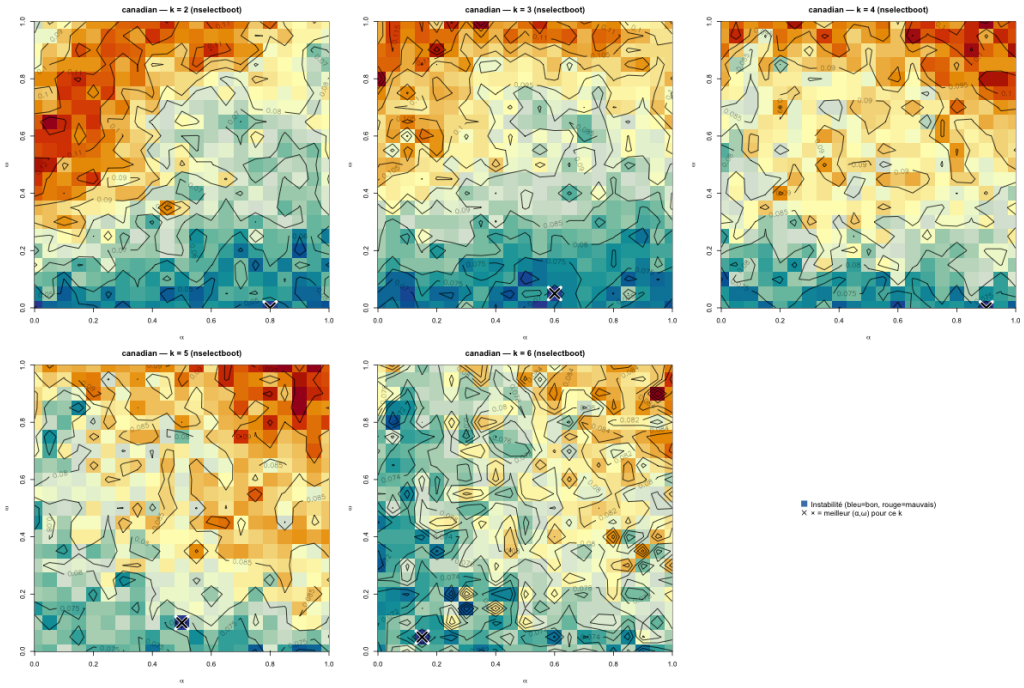

6.2 AEMET

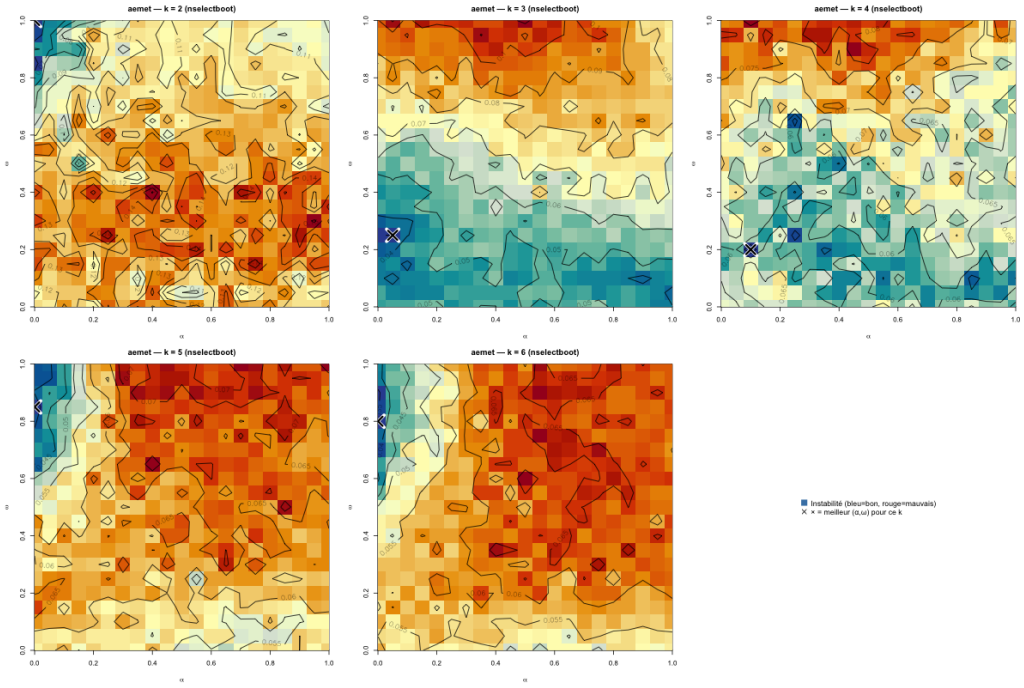

6.3 Growth

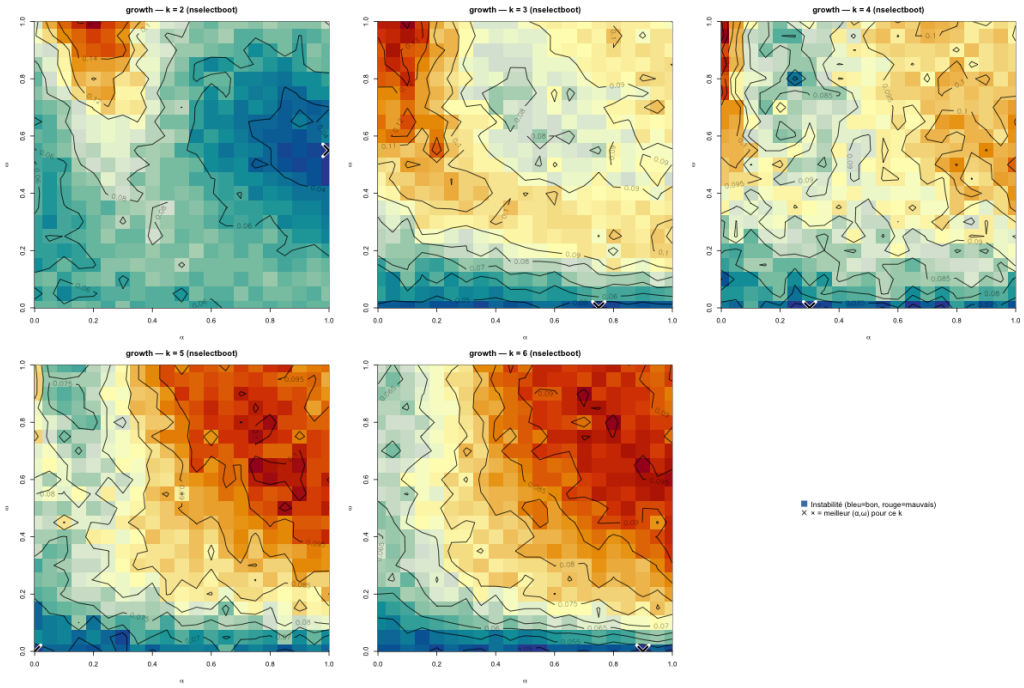

6.4 Tecator

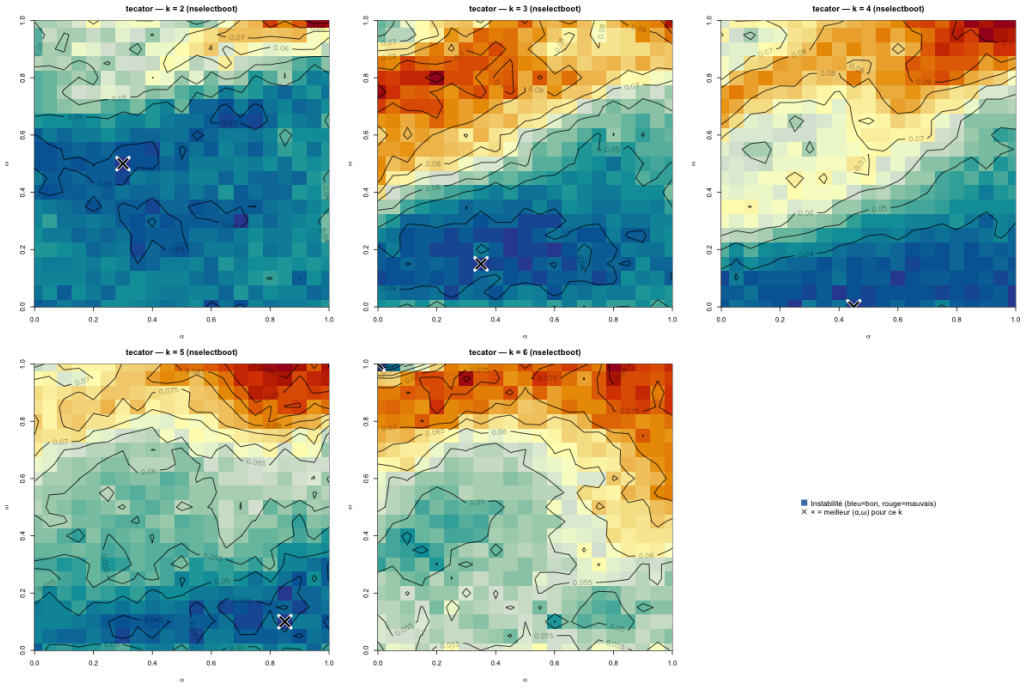

7 Etudes sur données simulées

On applique la **même idée** que plus haut à des **données simulées**, en quatre situations notées S1 à S4. Dans chaque cas on connaît le vrai nombre de groupes $k_{\text{vrai}} = 3$ ici : on compare avec ce que la méthode retient sur la grille de (α, ω).

Résultats chiffrés (seed fixée à 1). Pour chaque situation, le tableau indique : la part des couples (α, ω) de la grille pour lesquels le k choisi par la méthode est exactement le vrai k ; la

médiane des k choisis sur toute la grille ; le *mode* (valeur la plus fréquente). Ces nombres viennent d'un calcul **plus léger** qu'en données réelles : grille 6×6 en (α, ω) (pas de 0,05 entre les points), et $B = 60$ tirages bootstrap au lieu de $B = 150$, pour limiter le temps de calcul.

Scénario	**Seed**	k_{vrai}	**Prop.** $k_{\text{opt}} = k_{\text{vrai}}$	**Médiane** k_{opt}	**Mode** k_{opt}
S1	1	3	0,917	3	3
S2	1	3	0,722	3	3
S3	1	3	0,083	5,5	6
S4	1	3	0,000	6	6

TABLE 2 – Données simulées : grille 6×6, $B = 60$, graine 1. Un calcul aussi fin que sur les données réelles (21×21, $B = 150$) est possible mais beaucoup plus long.

Observation sur les heatmaps. Pour chaque situation on trace une carte par valeur de k testée : le **bleu** correspond à une faible instabilité (c'est mieux), le **rouge** à une instabilité forte. En lisant les quatre figures avec le tableau 2, on voit une différence nette entre les deux premiers cas et les deux derniers. Pour **S1** et **S2**, les zones les plus bleues concernent souvent $k = 3$, ce qui va dans le sens du vrai k et du tableau (beaucoup de couples (α, ω) choisissent le bon k). Pour **S3** et surtout **S4**, les cartes montrent plutôt des instabilités minimales pour des k plus grands que 3 : visuellement, le "bon" niveau se décale, ce qui colle au fait que la méthode retient rarement ou jamais $k = 3$ sur toute la grille.

Les quatre cartes. Même réglage que pour le tableau 2.

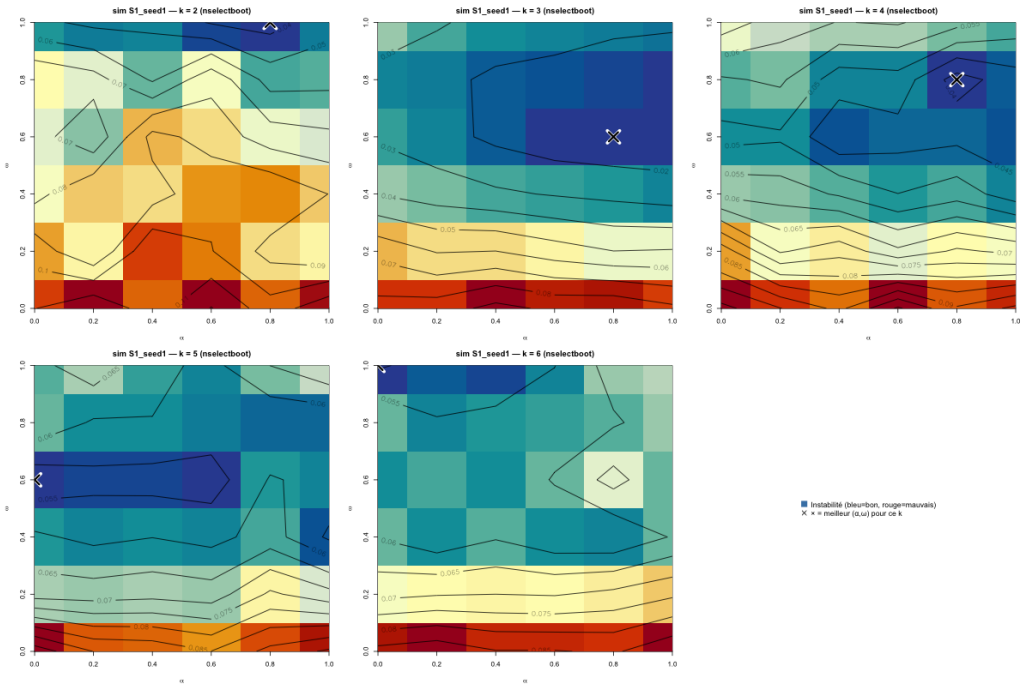

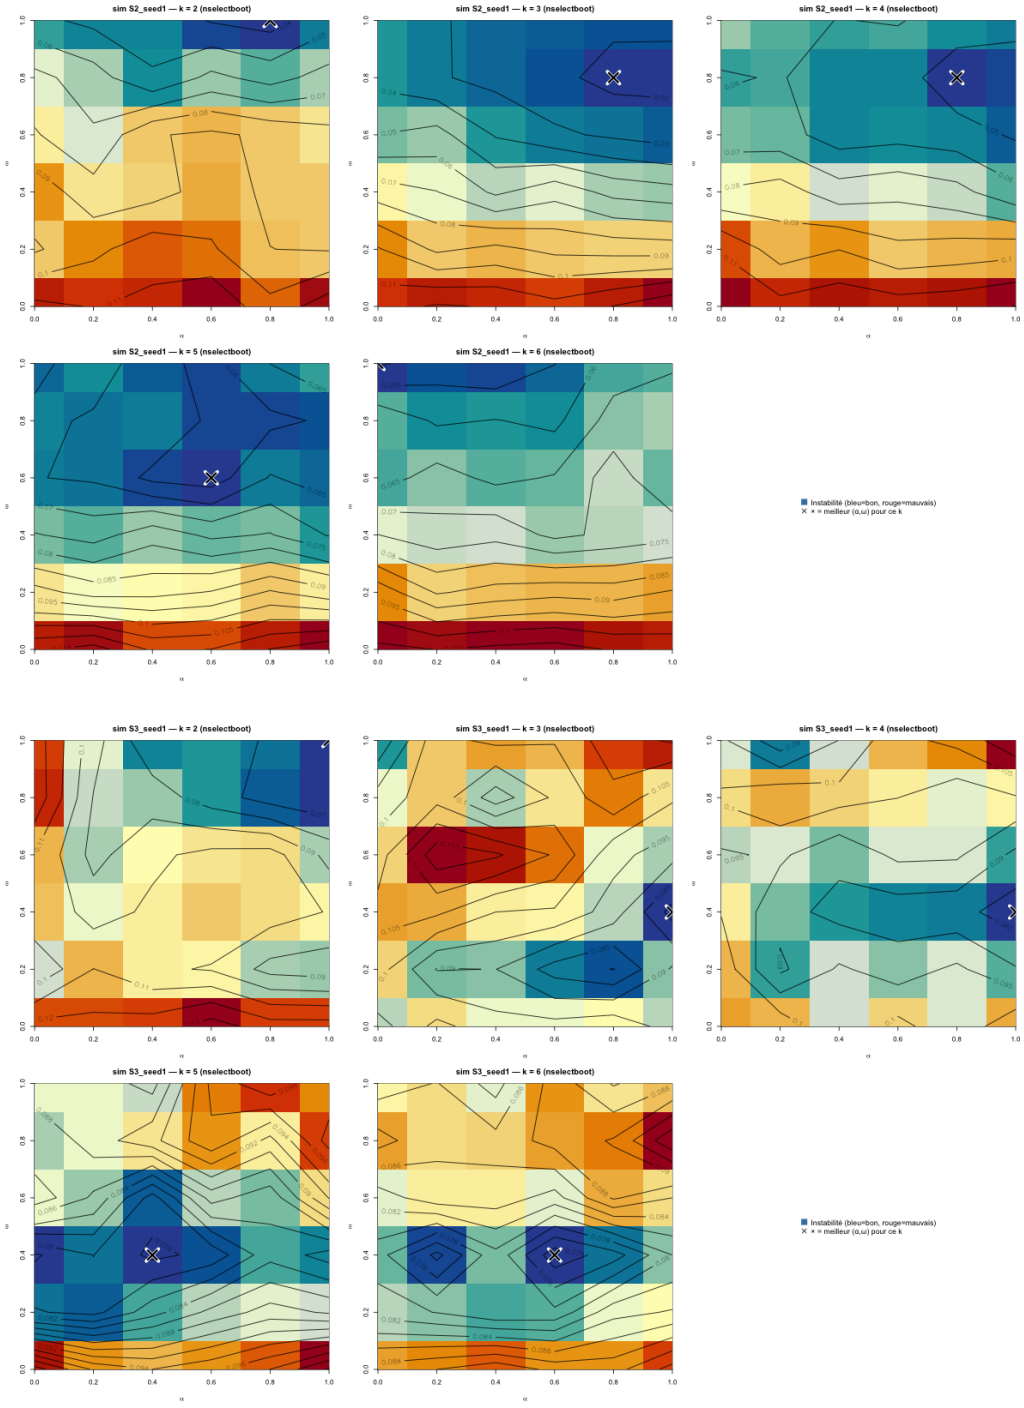
sim S2_seed1 — k = 2 (nselectboot)
sim S2_seed1 — k = 3 (nselectboot)
sim S2_seed1 — k = 4 (nselectboot)
sim S2_seed1 — k = 5 (nselectboot)
sim S2_seed1 — k = 6 (nselectboot)
Instabilité (bleu=bon, rouge=mauvais)
× = meilleur (α,ω) pour ce k
sim S3_seed1 — k = 2 (nselectboot)
sim S3_seed1 — k = 3 (nselectboot)
sim S3_seed1 — k = 4 (nselectboot)
sim S3_seed1 — k = 5 (nselectboot)
sim S3_seed1 — k = 6 (nselectboot)
Instabilité (bleu=bon, rouge=mauvais)
× = meilleur (α,ω) pour ce k

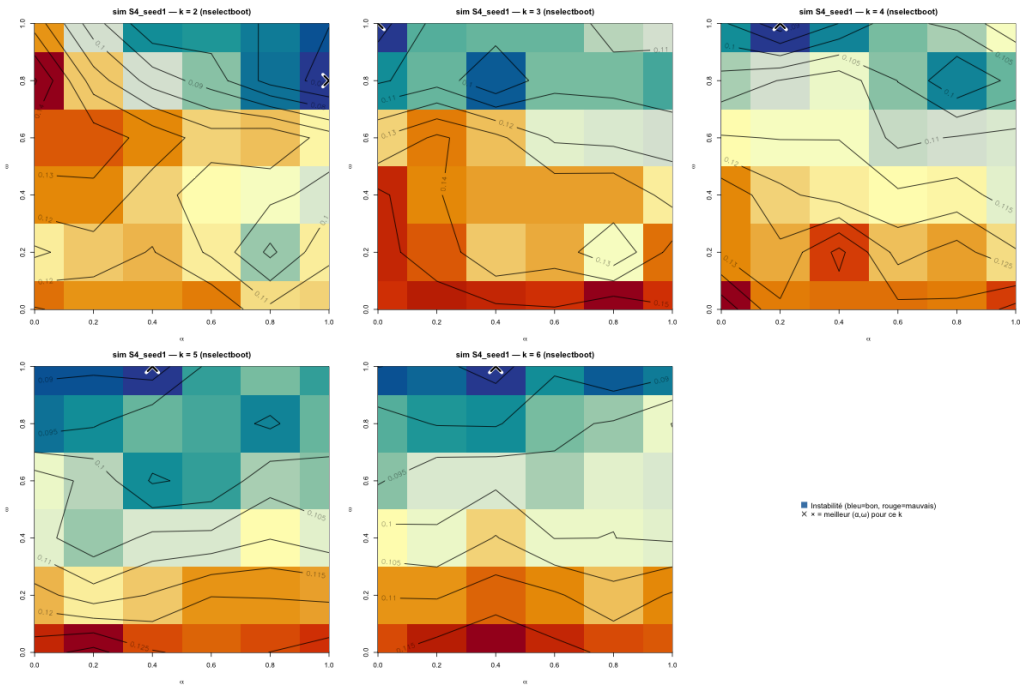

8 Paramètres des expériences

- Grille $\alpha, \omega \in \{0, 0.05, \ldots, 1\}$ (21×21).
- $k \in \{2, \ldots, 6\}$, $B = 150$ répétitions bootstrap pour nselectboot.
- Même prétraitement que le pipeline principal : `src/01_lissage.R`, `src/02_fpca.R`, `src/03_distances.R`.
- **Données simulées (réglage utilisé dans ce rapport) :** grille 6×6 en (α, ω), $B = 60$, $k \in \{2, \ldots, 6\}$. On peut en faire une version aussi fine que pour les données réelles (21×21, $B = 150$), au prix d'un temps de calcul beaucoup plus long.

9 Conclusion

L'expérience 1 s'appuie sur une méthode publiée (instabilité bootstrap, Fang & Wang) pour choisir k à (α, ω) fixé, puis explore toute la grille. Les labels servent uniquement à l'ARI et aux matrices de confusion, pas au choix de (k, α, ω). Les études sur données simulées illustrent la méthode quand le vrai k est connu ; elles ne remplacent pas l'étude sur les quatre jeux réels.

Références :

- Fang, Y., Wang, J. (2012). Selection of the number of clusters via the bootstrap method. *Computational Statistics and Data Analysis*, 56(3), 468–477.