Expérience 01 — Sélection par stabilité du clustering

Pierre Chambet

Mars 2026

Résumé

On teste la stabilité bootstrap comme critère de sélection du triplet (k, α, ω) pour le clustering mixte fonctionnel + vectoriel (Dw + PAM). Grille fine 21×21, $B = 150$ répétitions. Sur quatre jeux de données labellisés, la stabilité sélectionne $k = 2$ pour tous les datasets. On analyse les triplets retenus, les ARI obtenus, les matrices de confusion et la sensibilité au choix de B.

Table des matières

1 Contexte et objectif **2**

2 Protocole expérimental **2**
2.1 Algorithme de stabilité . . . 2
2.2 Paramètres utilisés . . . 2
2.3 Choix des cas . . . 2

3 Résultats principaux **3**
3.1 Tableau synthétique . . . 3
3.2 Observations immédiates . . . 3

4 Matrices de confusion **3**
4.1 Canadian Weather ($k_{\text{stab}} = 2$) . . . 3
4.2 AEMET ($k_{\text{stab}} = 2$) . . . 4
4.3 Growth ($k_{\text{stab}} = 2$) . . . 4
4.4 Tecator ($k_{\text{stab}} = 2$) . . . 4

5 Ce qui fonctionne **4**

6 Ce qui ne fonctionne pas (ou mal) **5**

7 Sensibilité au choix de B **5**

8 Questions soulevées **5**

9 Figures **5**
9.1 Canadian Weather . . . 6
9.2 AEMET . . . 6
9.3 Growth . . . 7
9.4 Tecator . . . 7

10 Conclusion provisoire **7**

1 Contexte et objectif

Le rapport de synthèse identifie la **sélection automatique des paramètres** (α, ω) et du nombre de clusters k comme verrou principal en clustering non supervisé. La silhouette, utilisée par défaut, conduit souvent à des choix sous-optimaux (ex. sur Canadian Weather : silhouette préfère $\omega = 0$ alors que l'ARI-optimal est proche de $\omega = 0.8$).

L'idée testée ici : le **bon triplet** (k, α, ω) est celui qui produit des clusters **reproductibles** lorsqu'on perturbe les données. On mesure cette reproductibilité par bootstrap.

2 Protocole expérimental

2.1 Algorithme de stabilité

Pour chaque triplet (k, α, ω) dans une grille :

1. Calculer la partition $\mathcal{C}$ sur les n individus complets (PAM avec la distance $D_w(\alpha, \omega)$).
2. Répéter B fois :
   — Sous-échantillonner aléatoirement 80 % des individus.
   — Recalculer D_w et la partition $\mathcal{C}_b^*$ sur ce sous-échantillon.
   — Mesurer l'ARI entre $\mathcal{C}$ (restreinte aux individus présents) et $\mathcal{C}_b^*$.
3. Stabilité $= \frac{1}{B} \sum_{b=1}^{B} \mathrm{ARI}(\mathcal{C}, \mathcal{C}_b^*)$.

Le triplet avec stabilité maximale est retenu.

2.2 Paramètres utilisés

— **Grille** : $\alpha, \omega \in \{0, 0.05, 0.1, \ldots, 1\}$ (21 valeurs chacun, pas 0.05), $k \in \{2, 3, 4, 5, 6\}$.
— **Bootstrap** : $B = 150$ répétitions, sous-échantillon = 80 %.
— **Datasets** : Canadian Weather, AEMET, Growth, Tecator.

Au total : $21 \times 21 \times 5 = 2205$ triplets par dataset, chacun nécessitant 151 exécutions de PAM (1 partition complète + 150 sur sous-échantillons).

2.3 Choix des cas

Les quatre datasets couvrent des contextes variés :
— **Canadian Weather** (35 stations, 4 régions) : météo, forte structure géographique.
— **AEMET** (73 stations, 4 zones) : météo Espagne.
— **Growth** (93 enfants, 2 classes M/F) : courbes de croissance.
— **Tecator** (215 spectres, 3 niveaux de gras) : spectroscopie NIR.

On les a choisis car (1) ils sont labellisés (évaluation par ARI possible), (2) ils diffèrent par n, k réel et nature des données, (3) le rapport de synthèse les utilise déjà pour les stratégies A, B, C.

3 Résultats principaux

3.1 Tableau synthétique

Dataset	n	k_{vrai}	k_{stab}	α	ω	**Stab.**	**ARI**
Canadian	35	4	2	0.30	0.00	0.973	0.541
AEMET	73	4	2	0.00	1.00	0.989	0.267
Growth	93	2	2	1.00	0.45	0.983	0.719
Tecator	215	3	2	0.40	0.30	0.985	0.467

TABLE 1 – Triplet stabilité-optimal et ARI obtenu pour chaque dataset (grille 21×21, $B = 150$).

3.2 Observations immédiates

— Avec $B = 150$ et la grille fine, la stabilité sélectionne **toujours** $k = 2$ sur les quatre datasets.

— Les triplets (α, ω) diffèrent : Canadian favorise $(\alpha = 0.3, \omega = 0)$ (fonctionnel type D_1), AEMET choisit $(\alpha = 0, \omega = 1)$ (vectoriel seul), Growth $(\alpha = 1, \omega = 0.45)$, Tecator $(\alpha = 0.4, \omega = 0.3)$ (mix).

— L'ARI varie de 0.27 (AEMET) à 0.72 (Growth). Growth, seul dataset avec $k_{\text{vrai}} = 2$, obtient le meilleur ARI.

4 Matrices de confusion

Pour chaque dataset, la matrice de confusion croise les **vraies classes** (lignes) et les **clusters prédits** (colonnes) par PAM avec le triplet stabilité-optimal.

4.1 Canadian Weather ($k_{\text{stab}} = 2$)

	Cluster 1	Cluster 2
Arctic	0	3
Atlantic	15	0
Continental	1	11
Pacific	1	4
Total	17	18

TABLE 2 – Canadian : 4 régions réduites à 2 clusters. Atlantic (15/15) et Arctic (3/3) bien séparés ; Continental et Pacific partiellement mélangés.

Interprétation : Le cluster 1 regroupe Atlantic (15/15) + une partie de Continental et Pacific. Le cluster 2 regroupe Arctic (3/3) + majorité de Continental (11), Pacific (4). La fusion de 4 classes en 2 brouille la structure fine des régions climatiques.

4.2 AEMET ($k_{\text{stab}} = 2$)

	Cluster 1	Cluster 2
Atlantique	13	0
Continental	20	1
Méditerranée	6	12
Sud	3	18
Total	42	31

TABLE 3 – AEMET : $\omega = 1$ (Ds seul). Les clusters suivent surtout la géographie/altitude.

Interprétation : La stabilité choisit $\omega = 1$, i.e. la distance purement vectorielle (altitude, lat, lon). Atlantique et Continental se retrouvent dans le cluster 1 ; Méditerranée et Sud se partagent entre les deux. L'ARI faible (0.27) reflète un mélange important.

4.3 Growth ($k_{\text{stab}} = 2$)

	Cluster 1	Cluster 2
Garçon	38	1
Fille	6	48
Total	44	49

TABLE 4 – Growth : très bon accord (ARI = 0.72).

Interprétation : Seul dataset où $k_{\text{stab}} = k_{\text{vrai}}$. Les clusters correspondent presque aux classes M/F : 38 garçons et 48 filles bien classés, 7 erreurs (6 filles en cluster 1, 1 garçon en cluster 2). Le triplet ($\alpha = 1, \omega = 0.45$) privilégie la forme des courbes (D1).

4.4 Tecator ($k_{\text{stab}} = 2$)

	Cluster 1	Cluster 2
Maigre	4	108
Moyen	32	30
Gras	41	0
Total	77	138

TABLE 5 – Tecator : 3 classes fusionnées en 2. Gras vs reste.

Interprétation : Le cluster 1 isole Gras (41/41) + une partie de Moyen. Le cluster 2 regroupe Maigre (108/112) et le reste de Moyen. La frontière Maigre/Moyen est floue ; la stabilité privilégie la séparation Gras vs non-Gras.

5 Ce qui fonctionne

— La stabilité fournit une **mesure reproductible** : les triplets retenus donnent des partitions stables sous bootstrap.

— Sur **Growth**, où $k_{\text{vrai}} = 2$, le triplet stabilité-optimal ($k = 2, \alpha = 1, \omega = 0.45$) obtient un très bon ARI (0.72) et une confusion faible.
— Les heatmaps de stabilité (grille fine 21×21) montrent des **zones cohérentes** : pour un k donné, les régions de haute stabilité se regroupent. Le symbole $\times$ indique le meilleur triplet par k.

6 Ce qui ne fonctionne pas (ou mal)

— **Canadian, AEMET, Tecator** : $k_{\text{stab}} = 2$ alors que $k_{\text{vrai}} \in \{3, 4\}$; la fusion brouille la structure.
— **AEMET** : ARI faible (0.27), correspondance partielle avec les 4 zones réelles.
— La stabilité reste **sensible au choix de** B : Canadian varie fortement selon B (voir § 7).

7 Sensibilité au choix de B

Des exécutions préalables avec différentes valeurs de B (grilles 11×11 et 21×21) ont montré que le triplet optimal **varie selon** B, notamment pour Canadian Weather :

B	**Canadian** (α, ω)	**AEMET** k	**Tecator** k
50	$(0.9, 0)$	2	2
55	$(0.3, 0)$	2	2
70	$(0.9, 0.9)$	3	4
150	$(0.3, 0)$	2	2

TABLE 6 – Triplet optimal pour Canadian ; k retenu pour AEMET et Tecator, selon B. Canadian alterne entre $(0.3, 0)$ et $(0.9, 0.9)$.

Interprétation : Canadian est le plus sensible : avec B=55 ou B=150 (grille fine), le triplet $(0.3, 0)$ l'emporte ; avec B=70, c'est $(0.9, 0.9)$. La différence de stabilité entre ces triplets est très faible (~ 0.001), d'où une instabilité du classement. AEMET et Tecator varient en k (2, 3 ou 4) selon B. Un B plus grand (150) avec une grille fine tend à converger vers $k = 2$ pour tous les datasets.

8 Questions soulevées

1. **Convergence avec** B : $B = 150$ avec grille fine donne $k = 2$ partout. Faut-il poursuivre l'augmentation de B ou accepter ce biais structurel vers les petits k ?
2. **Stabilité vs silhouette** : comparaison systématique sur les 4 datasets pour (k, α, ω) et ARI.
3. **Combinaison de critères** : un vote entre stabilité, silhouette et éventuellement gap/prediction strength permettrait-il de mieux choisir (k, α, ω) ?

9 Figures

Les heatmaps de stabilité sont générées par `analyse_stabilite.R` et sauvegardées dans `figures/`. Chaque figure montre, pour un dataset et pour $k = 2, \ldots, 6$, la stabilité en fonction de (α, ω). Le symbole $\times$ indique le meilleur triplet pour ce k. Rouge = haute stabilité, jaune = faible.

9.1 Canadian Weather

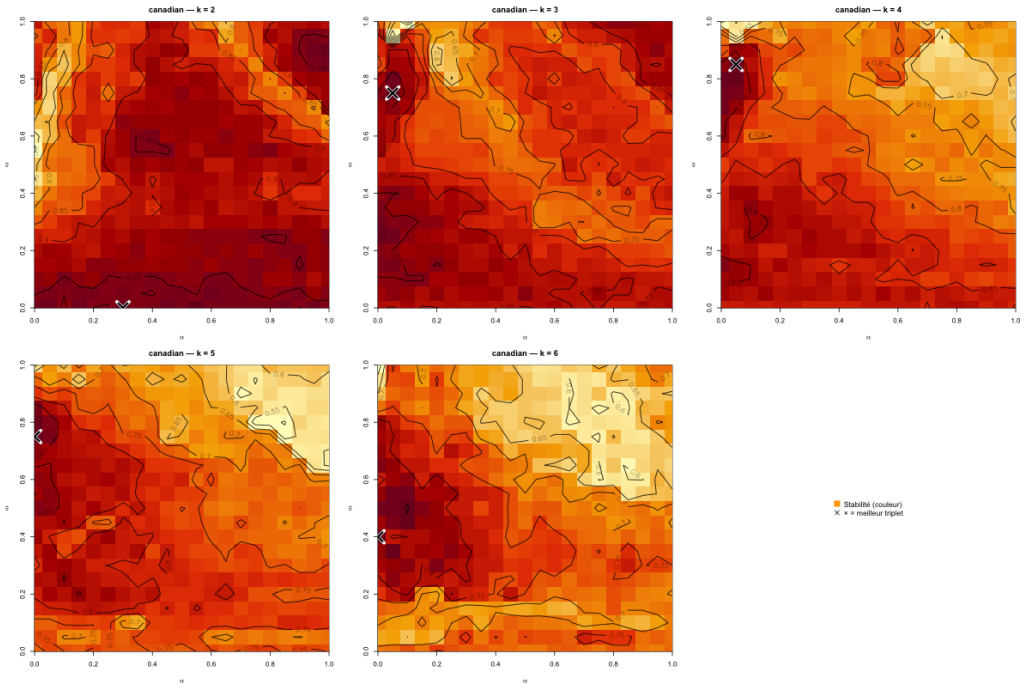

9.2 AEMET

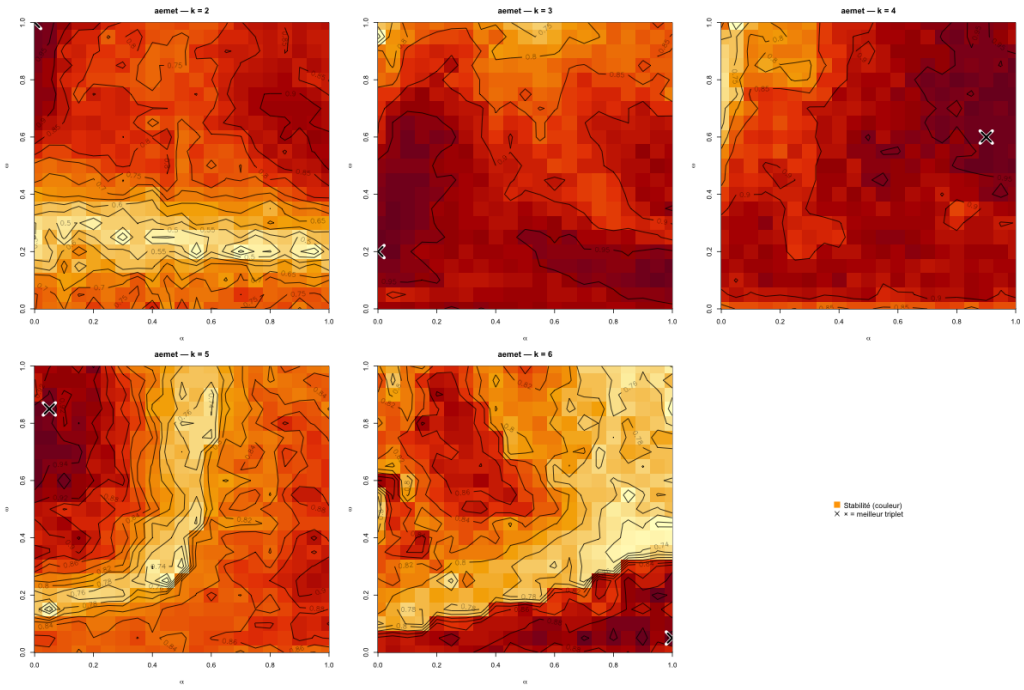

9.3 Growth

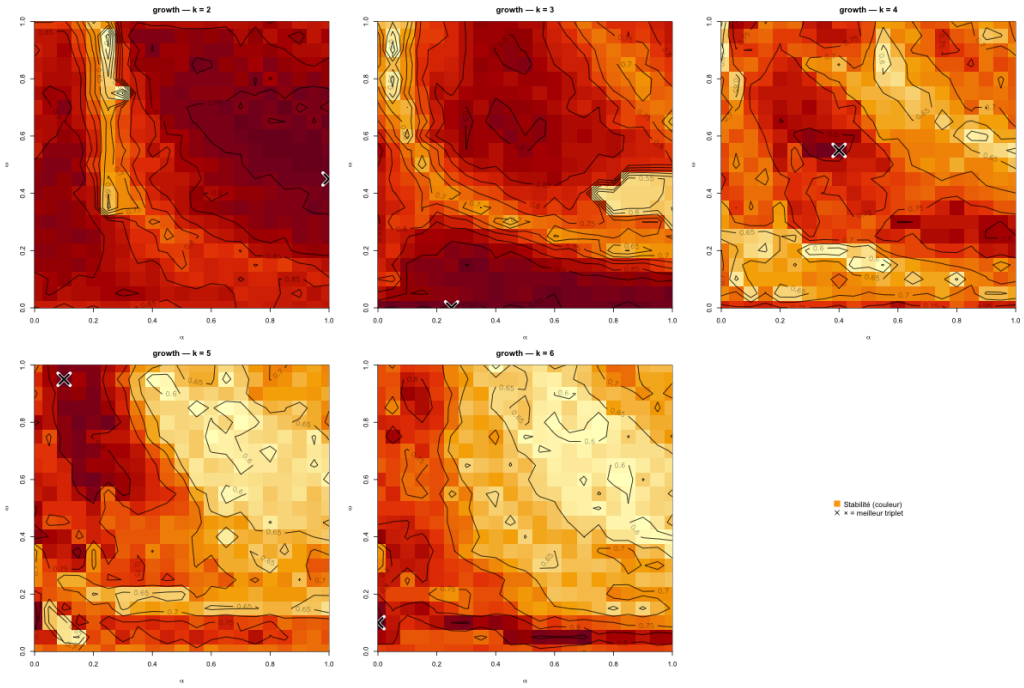

9.4 Tecator

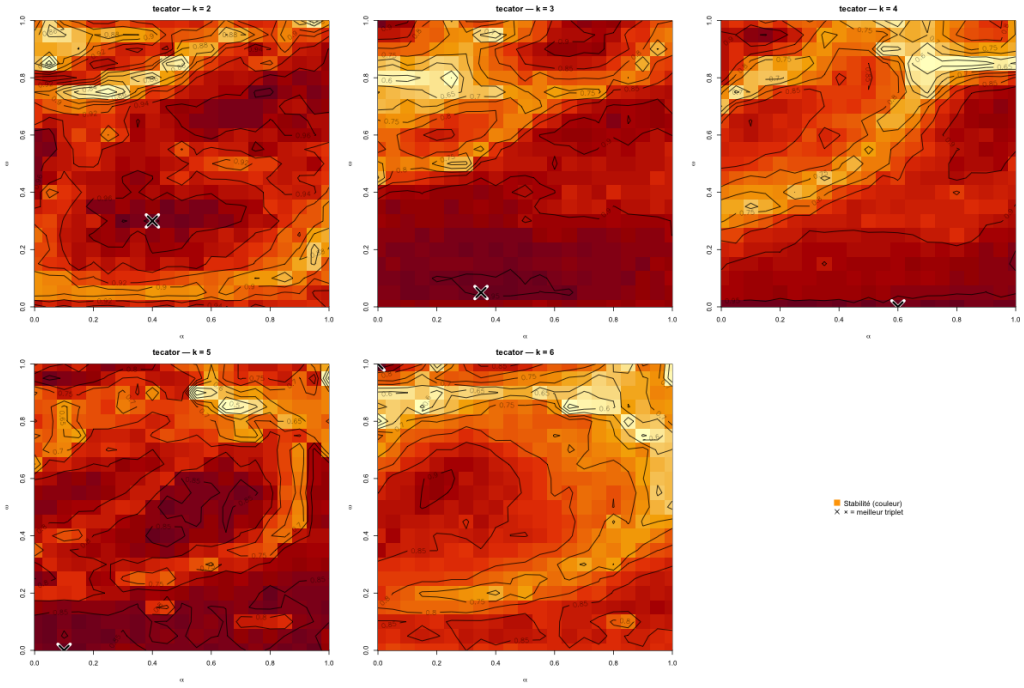

10 Conclusion provisoire

La stabilité bootstrap (grille 21×21, $B = 150$) est un critère **intéressant** (pas de labels, interprétable, reproductible). Elle sélectionne $k = 2$ pour tous les datasets. Sur Growth ($k_{\text{vrai}} = 2$), elle performe très bien (ARI 0.72). Sur Canadian, AEMET et Tecator, la fusion en 2 clusters dégrade l'ARI par rapport à un choix oracle.

L'étude de la **sensibilité à** B (tab. 6) montre que Canadian alterne entre $(0.3, 0)$ et $(0.9, 0.9)$ selon B et la grille. Un B plus grand réduit la variance de l'estimateur mais ne garantit pas un

choix plus « juste » en termes d'ARI.

Pistes : (1) combiner stabilité avec d'autres critères (vote) ; (2) tester des corrections du biais vers $k = 2$; (3) utiliser les heatmaps pour identifier des zones robustes de (α, ω).